

Cours : Cloud & Big Data (ESGIS, M1 IA & Big Data, 2025-2026)
Projet fil rouge : plateforme de données Anfa (transport bus, Lomé)
Poids : 40 % de la note finale (les TP rendus comptent pour les 60 % restants)
Format : PDF, 8 à 15 pages, captures d'écran obligatoires
Rédaction : à la première personne, à partir de VOS propres livrables
(branches seance-NN, captures, DAGs, buckets, bugs simulés)

Contexte

Anfa (société fictive de transport bus de Lomé, ~100 bus) a validé le prototype de plateforme de données que vous avez construit brique par brique pendant le semestre : stockage objet, conteneurisation, orchestration Kubernetes, Infrastructure as Code, traitement Spark distribué, pipelines Airflow, streaming Kafka, CI/CD, monitoring et MLOps.

Le Directeur Technique veut désormais passer en **production réelle**. Il vous demande un **document technique de référence** : ni un cours, ni un tutoriel, mais **votre mémoire d'ingénieur** sur la plateforme que *vous* avez montée. À partir de ce rapport, il doit pouvoir décider quoi garder, quoi changer, et à quel risque.

Important. Ce rapport ne peut pas être rédigé sans votre vécu réel des TP. Vous écrivez à la première personne, en vous appuyant sur vos propres captures, vos vrais noms de ressources (buckets, topics, DAGs, ports) et les pannes que vous avez vous-même déclenchées puis réparées.

Ce que vous devez rendre

Le rapport doit répondre aux **5 parties** ci-dessous, dans cet ordre.

Partie 1 : Cartographie de MA plateforme (le *quoi*)

- Un **schéma d'architecture unique** reliant les 10 briques : MinIO, Docker, Kind, Terraform, Spark, Airflow, Kafka, CI/CD (GitHub Actions), Prometheus/Grafana, MLflow.
- Montrez **le chemin de la donnée** : du référentiel CSV (lignes, arrêts, bus, tarifs) jusqu'au modèle de prédiction d'affluence.
- **Contrainte** : le schéma est dessiné par vous (à la main ou avec un outil), avec les **vrais noms** de vos buckets, topics, DAGs et ports. Une capture d'écran par brique, prise dans *votre* environnement.

Partie 2 : Le journal des arbitrages (le *pourquoi*)

Pour **5 choix techniques** rencontrés en TP, expliquez la décision **et l'alternative écartée**. Par exemple :

- Kind plutôt que Minikube.
- Provider Docker de Terraform plutôt qu'un provider cloud (AWS...).
- spark-submit piloté via le socket Docker plutôt que le SparkSubmitOperator officiel.
- Logique métier isolée dans anfa_logic.py plutôt que testée directement dans Airflow.
- Fichier sentinelle /tmp/anfa_en_panne plutôt qu'un docker stop de l'exporter (séance 9).

Pour chaque choix, répondez à la question : « **qu'est-ce qui casserait si on avait fait l'inverse ?** »

Partie 3 : Analyse du fil rouge « ça tourne mais c'est inutile »

Le cours répète ce principe à travers trois séances : idempotence et gestion d'échec Airflow (S6), fraîcheur des données (S9), data drift MLflow (S10).

- **Racontez les trois pannes que vous avez vous-même simulées** en TP.
- Expliquez pourquoi un statut success vert peut **mentir**.
- Reliez ce principe aux offsets Kafka (S7) et au state Terraform (S4) : en quoi participent-ils de la même idée (« garder la trace plutôt que présumer ») ?

Partie 4 : Le passage au cloud réel (la *transposition*)

Le cours martèle que le code est « transposable tel quel » vers le cloud. **Testez cette promesse.**

Pour **3 briques**, dites ce qui change **exactement** en migrant vers un cloud public :

- MinIO vers Amazon S3.
- Kind vers EKS / GKE.
- Spark standalone vers EMR / Dataproc.

Précisez : ce qui **coûte de l'argent**, une **estimation d'ordre de grandeur** du coût mensuel, et ce que le **vendor lock-in** réintroduit malgré la portabilité annoncée.

Partie 5 : Souveraineté et conformité (le *jugement*)

En vous appuyant sur la séance 10 (Loi togolaise **2019-014** sur les données personnelles, **Convention de Malabo**, RGPD) :

La future application mobile Anfa collectera la **géolocalisation des passagers** et l'**historique mobile money**.

- **Où héberger ces données ?** Défendez un choix parmi : cloud US, cloud européen, on-premise à Lomé.
- Pesez explicitement **coût, conformité et souveraineté**.
- Il n'existe pas de bonne réponse unique : ce qui est noté, c'est la **qualité de l'argumentation**.

Barème (sur 20)

Critère	Points
Architecture + ancrage réel (captures, vrais noms de ressources)	5
Qualité des arbitrages et des alternatives écartées	4
Analyse du fil rouge (pannes réellement vécues)	4
Transposition cloud + estimation des coûts	3
Conformité et souveraineté argumentées	2
Clarté, cohérence transversale, esprit critique	2

À propos de l'usage de l'IA

Vous **pouvez** utiliser un assistant IA : vous ne serez pas pénalisés pour cela. Mais le sujet est conçu pour qu'une réponse générée sans réflexion ne suffise pas.

Une copie rédigée uniquement par IA sera **générique, sans vos captures, avec de faux noms de ressources et des contradictions entre les parties**. Elle est facile à repérer et sera notée comme telle.

Une bonne copie prouve que vous avez **poussé l'outil loin ET réfléchi par vous-même** : elle est ancrée dans votre environnement réel, elle justifie des choix, elle assume des arbitrages et elle reste cohérente d'un bout à l'autre.